EUREKA PROJECT

⟨LLM 보안⟩

안전한 도구 호출 시스템

팀명: A+받고10조

김민규 · 아이디어 세부 제공

김석준 · 발표, 아이디어 다듬기

김수연 · 아이디어 제공, 포스터 제작

오영민 · 아이디어 세부 제공



파일 읽기 · 웹 검색 · 데이터베이스 · 이메일 전송

LLM의 능력에 안전장치를 더하다

작동 방식 FLOW

공통: 사용자 정보 또는 파일 › 입력 개인 정보 검사 › 프롬프트 안전성 검사 › 출력·URL 문서 보안 검사 › 정책 엔진

2 허용 › LLM 또는 외부 도구 호출 › 응답 또는 도구 결과 검사 › 위험도 평가 › 사용자에게 안내 및 확인 › 검사 로그 저장

3 주의 › 사용자 승인 요청

4 차단 › 사유 및 안전한 대안

보안 기술 발전 방향

코드 검사 기록지 → 프롬프트 인젝션 탐지 → URL 및 문서 검사 → 도구 호출 통제 → 개인화된 보안 대시보드

한계와 대응 LIMITS

기술적 한계

- 악성코드 여부를 완전하게 증명하기 어려움
- 오탐·미탐 가능성 → 신뢰도와 불확실성 함께 표시
- 검사 기능 자체가 표적이 될 수 있음
- 프롬프트 보안 탐지 우회 가능성

"안전하다"가 아니라
"위험 신호는 발견되지 않았으나 악성 여부는 보장하지 않는다"

윤리적 한계

- 위험도 결정 주체와 기준의 불확실성
- 오작동·피해 발생 시 책임 문제
- 보안 시스템 악용 가능성
- 이해 가능한 설명 제공, 탐지 규칙·임계값 보호

AI 활용: 포스터 제작 및 아이디어 구체화

출처: OWASP Top 10 for LLM Applications 2025